

R을 이용한 머신러닝

R 사용법

RStudio 설치

R 설치 및 사용법

R console 다운로드

- <http://www.r-project.org>에서 다운로드 (ver 3.x -> ver 4.x 로 업데이트)



[Home]

Download

CRAN

R Project

About R
Logo
Contributors
What's New?
Reporting Bugs
Conferences
Search
Get Involved: Mailing Lists
Developer Pages
R Blog

The R Project for Statistical Computing

Getting Started

R is a free software environment for statistical computing and graphics. It compiles and runs on a wide variety of UNIX platforms, Windows and MacOS. To [download R](#), please choose your preferred [CRAN mirror](#).

If you have questions about R like how to download and install the software, or what the license terms are, please read our [answers to frequently asked questions](#) before you send an email.

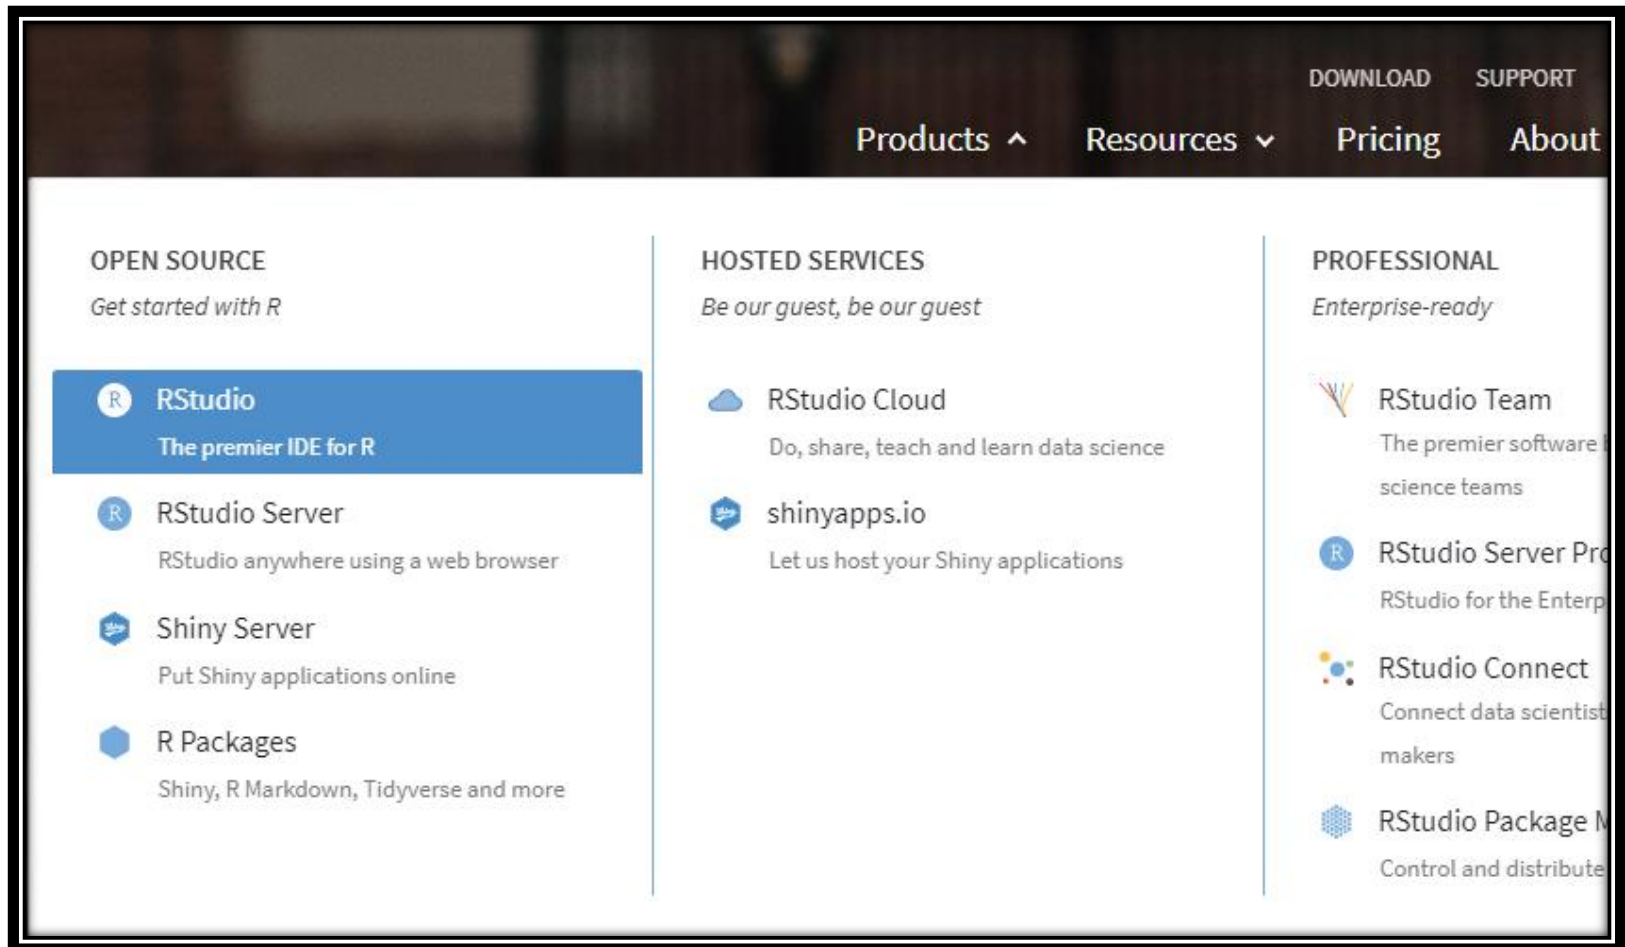
News

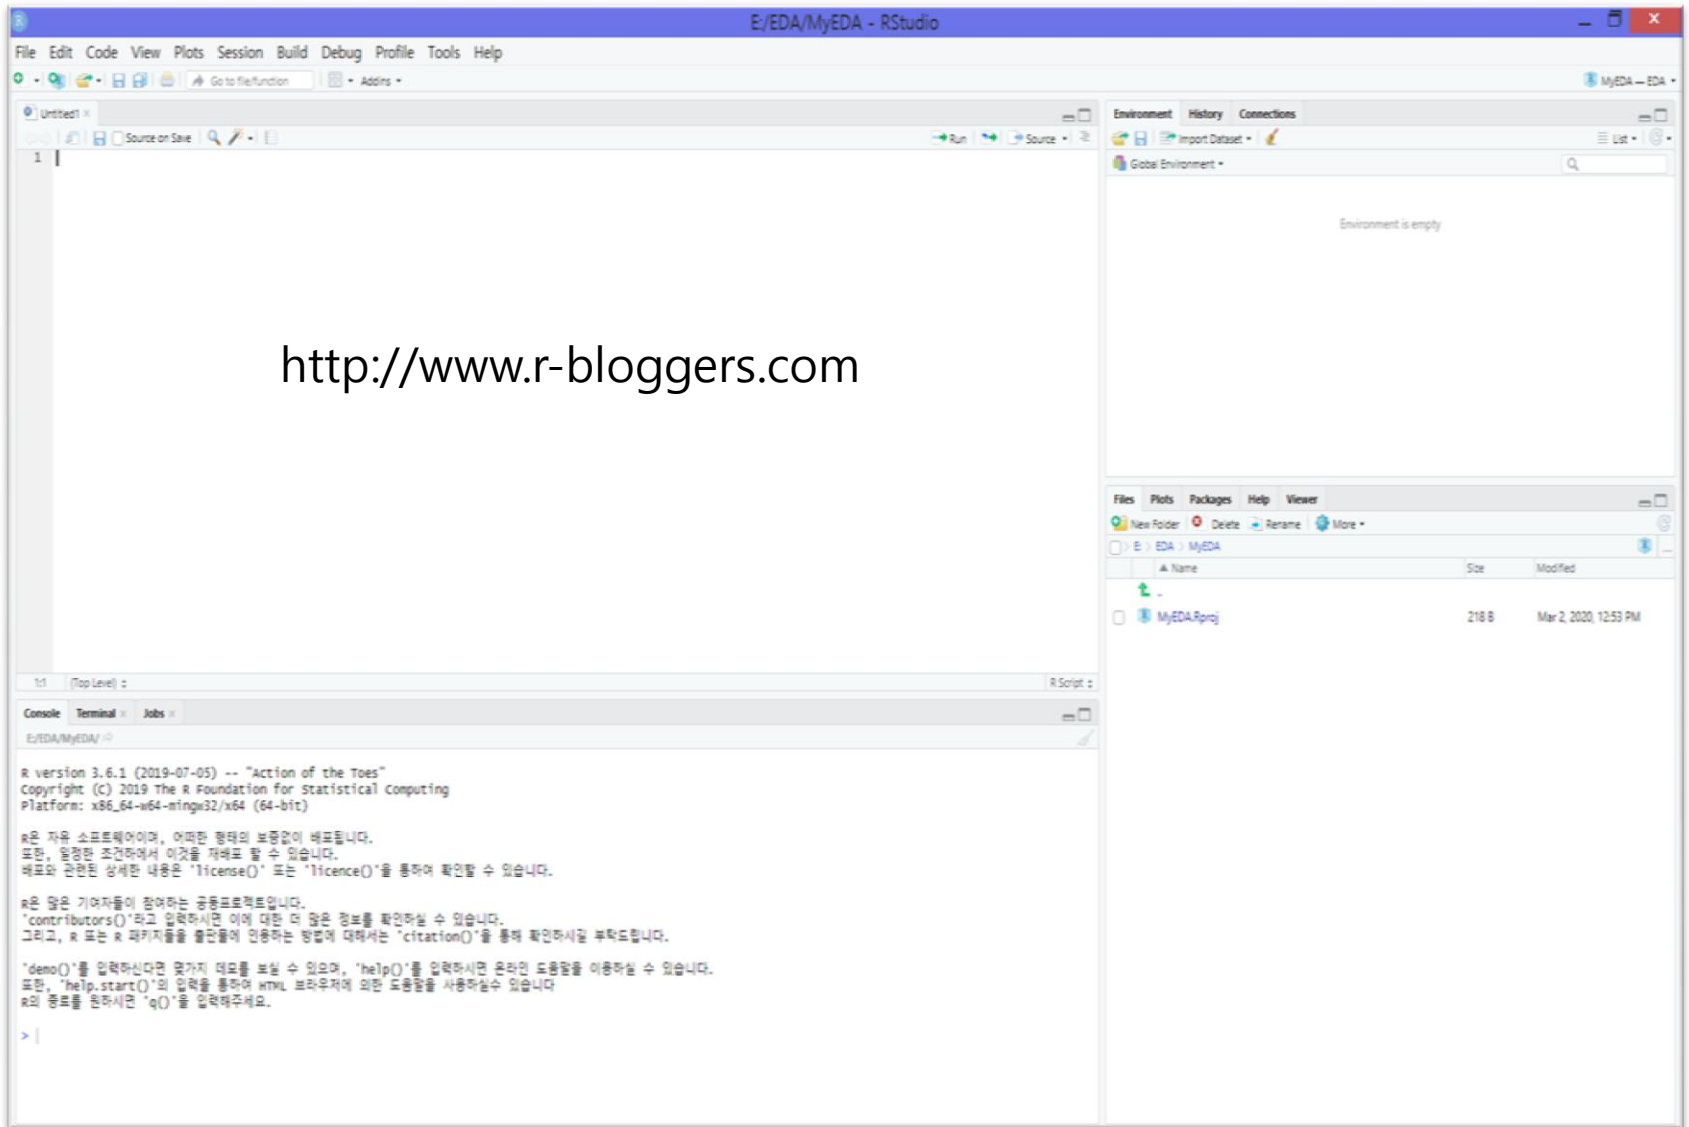
- [R version 4.0.2 \(Taking Off Again\)](#) has been released on 2020-06-22.
- [useR! 2020 in Saint Louis has been cancelled](#). The European hub planned in Munich will not be an in-person conference. Both organizing committees are working on the best course of action.
- [R version 3.6.3 \(Holding the Windsock\)](#) has been released on 2020-02-29.
- You can support the R Foundation with a renewable subscription as a [supporting member](#)

- 관리자 권한으로 프로그램 실행

Rstudio 다운로드

- <http://www.rstudio.com> 에서 Rstudio 다운로드 및 설치

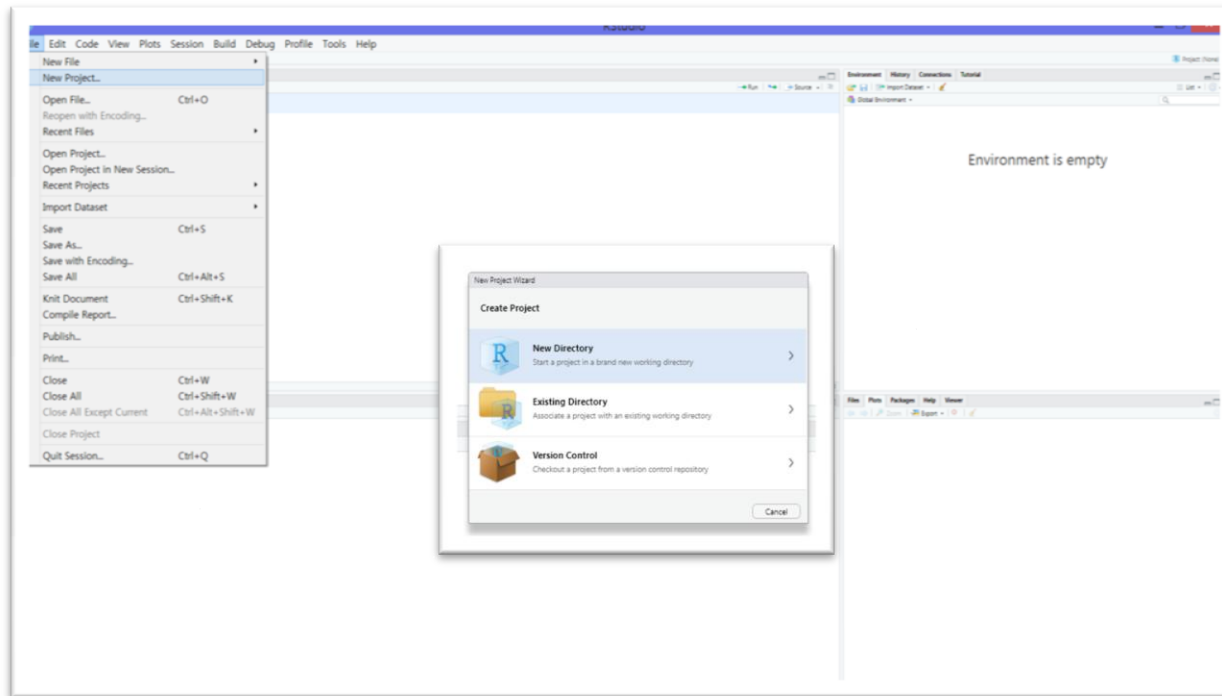




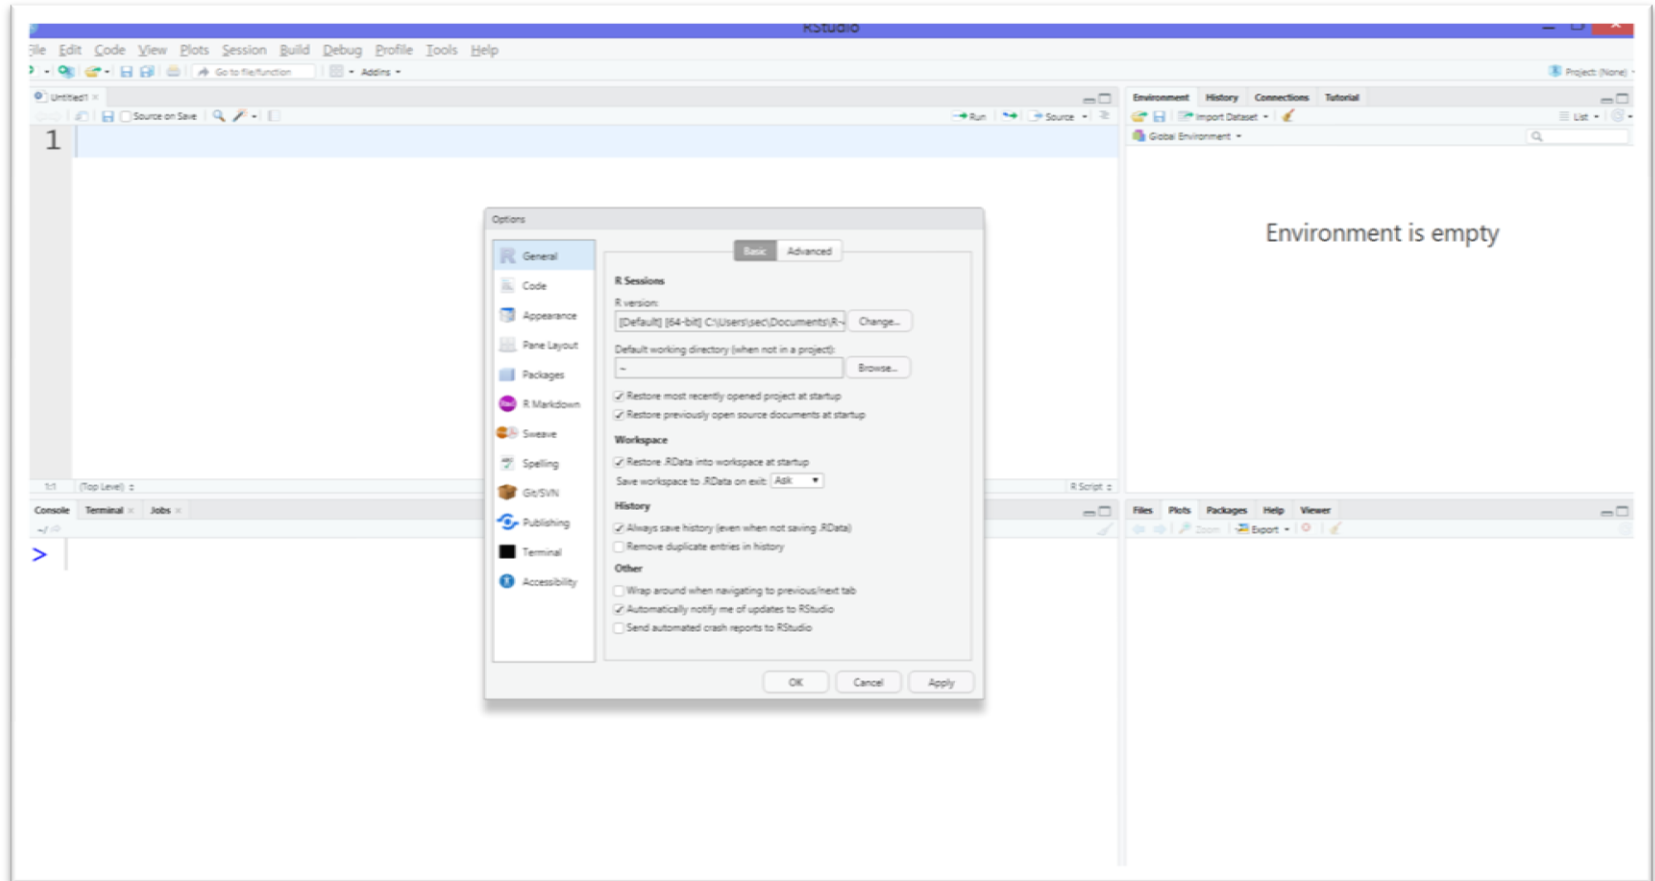
<http://www.r-bloggers.com>

Rstudio 프로젝트

- Rstudio 의 프로젝트 기능은 Rstudio 핵심 기능 중 하나.
- 프로젝트는 연관된 데이터, 결과물, 그래프 파일 등으로 구성
- 각각의 프로젝트는 각자 고유의 working디렉토리를 가진다.
- 프로젝트를 사용하면 작업을 잘 정돈할 수 있다.



Rstudio 옵션



프로그래밍의 6원칙

- 변수명
- 데이터형(선언이 필요없다-분석용) + 자료구조
 - 데이터 형 : 문자형, 숫자형, 논리형, Null
 - 구조 : 벡터, 행렬, 배열, 데이터프레임, 리스트
- 연산자
 - 산술, 논리, 비교, 연결 등
- 제어문
 - If/else
- 반복문
 - for, while
- 함수
 - Packages 함수 꾸러미

R 패키지

- Package 인스톨
 - `chooseCRANmirror()` : 선택 : # 입력
 - `install.packages("ggplot2")`
- Package 제거
 - `remove.packages()`
- Package 로딩
 - `library(ggplot2)`
- 업데이트
 - `update.packages(checkBuilt = TRUE, ask=false)`
- package 언로딩
 - `detach("package:tidyverse")`

변수명

- 변수선언
 - 변수명(객체이름) <- 값 : 새 객체가 생성
 - 변수명 = 값
- 변수명 규칙
 1. <- 할당 연산자. (alt + -)로 자동생성.
 2. 객체이름은 문자로 시작.(문자, 숫자,_,.만 포함)
 3. 따옴표와 괄호는 항상 짝을 이룸.
 4. 대/소문자 구분
 5. # 주석처리
 6. 세미콜론(;) : 여러 명령어를 한 줄에 입력
 7. rm() : 불필요한 객체(값)을 제거

R DataType

데이터 유형

```
#숫자
```

```
x <- 2
```

```
is.numeric(x)
```

```
class(x) #데이터 유형
```

```
#문자 : character
```

```
x <- "data"
```

```
is.character(x)
```

```
#문자 : factor
```

```
y <- factor("data")
```

```
is.factor(y)
```

```
is.character(y)
```

```
#문자의 길이
```

```
nchar(x)
```

```
nchar(y)
```

```
nchar("hello")
```

#날짜 및 시간

Sys.Date() #현재날짜

Sys.time() #현재날짜 및 시간

```
date1 <- as.Date("2020-09-08")
```

```
class(date1)
```

```
as.numeric(date1)
```

#1970년 1월1일을 기준으로 날짜와 초를 계산

```
date2 <- as.POSIXct("2020-09-08 16:30")
```

```
class(date2)
```

```
as.numeric(date2)
```

#논리형 : true, false

$2==3$ #2와 3은 같은가?

$2!=3$ #2와 3은 다른가?

$2<3$ #2가 3보다 작은가?

$2<=3$ #2가 3보다 작거나 같은가?

$2>3$ #2가 3보다 큰가?

$2>=3$ #2가 3보다 크거나 같은가?

`"data" == "stats"` #`"data"`가 `"stats"`와 같은가?

`"data" < "stats"` #`"data"`가 `"stats"`보다 작은가?

#결측값 ; . 또는 99(다른 통계P/G) , NA(R)

```
z <- c(1,2,NA,8,3,NA,3)
```

```
is.na(z) #결측값인지 아닌지 확인
```

```
zChar <- c("Hockey",NA,"Lacrosse")
```

```
is.na(zChar)
```

```
mean(z) # 요소 값이 NA인 벡터에 대해 mean을 적용하면?
```

```
mean(z, na.rm = TRUE) # 결측치 제거
```

#NULL ; 아무것도 없음을 의미

#단독으로 존재하고 벡터 안에 있을 수 없다.

#만약 벡터 안에 사용하면?

```
z <- c(1,NULL,3)
```

```
length(z)
```

R 연산자 및 함수

연산자 및 함수

R연산자	설 명	R연산자	설 명
<-	할당 연산자	>	크다
+, -, *, /	산술 연산자	>=	크거나 같다
^	제곱 연산자	<	작다
~	모형 표현에 사용	<=	작거나 같다
:	수열(모형에서는 교호작용)	, &&	객체의 첫 번째 요소만 비교
::	팩키지에서 함수 참조	%/%	나눗셈 몫
!	NOT	%%	나눗셈 나머지
&	AND	%*%	행렬곱
	OR	%in%	매칭 확인
==	Equal to	%any%	연산자생성
!=	Not equal	%>%	Pipe operator

파이프 연산자

- 함수를 호출하는 새로운 패러다임
- magrittr 패키지가 제공
- 기능
 - 파이프를 중심으로 왼쪽에 있는 값이나 객체가 파이프의 오른쪽에 오는 함수의 첫 번째 인자로 삽입하는 방식으로 사용
 - Ctrl + Shift + M
- 예제

```
library(magrittr)  
mean(x)
```

→

```
x %>% mean
```

- 문제

```
z <- c(1,2,NA,8,3,NA,3)  
sum(is.na(z))  
mean(z, na.rm = TRUE)
```

→

```
?
```

통계함수	
mean	산술평균
median	중간값
sd	표준편차
var	분산
max	최대값
min	최소값
IQR	사분위수 범위
range	범위
quantile	사분위수
sum	합계
prod	모든 원소의 곱
length	관측치 개수

데이터 전처리

- dplyr 패키지

함수	기능
filter()	행 추출
select()	열 추출
group_by()	집단별로 나누기
summarise()	통계치 요약
arrange()	정렬
mutate()	변수추가
left_join()	데이터 합치기(열)
bind_rows()	데이터 합치기(행)


R data structure

데이터 구조


Vector




Data Frame
(Table)




Matrix



Array



Lists



벡터

- R의 기본구조
- 동일한 데이터 형식
- 문자형, 수치형, 복소수형, 논리형
- NULL(값이 존재하지 않음, 길이=0), NA(결측치, 길이=1)

팩터

- 오직 범주형 변수나 서열 변수에 적용
- 정보 저장에 필요한 메모리 크기가 줄어듦.
- 문자형, 수치형 중 한가지만 사용

리스트

- 서로 다른 데이터 타입을 가짐

데이터프레임

- 데이터의 행과 열을 가지고 있는 구조 (2차원 구조)
- 동일한 개수의 값을 갖는 벡터나 팩터의 리스트
- 문자형, 수치형, 복소수형, 논리형

행렬

- 데이터의 행과 열을 갖는 2차원 표를 나타내는 데이터 구조
- 동일한 데이터 형식

R 데이터 구조

– 벡터

```
#vector 입력
subject_name <- c("John Doe","Jane Doe","Steve Graves")
temperature <- c(98.1, 98.6, 101.4)
flu_status <- c(FALSE, FALSE, TRUE)

#index 지정
temperature[2]
temperature[2:3]

#data 제외
temperature[-2]

#logical vector
temperature[c(TRUE, TRUE, FALSE)]
```


R 데이터 구조

– 팩터

```
#factor
```

```
gender <- factor(c("MALE","FEMALE","MALE"))
```

gender #Levels는 factor가 가질 수 있는 가능한 범주의 집합

```
#raw data에 없는 데이터 level 추가
```

```
blood <- factor(c("O","AB","A"),  
               levels = c("A","B","AB","O"))
```

```
blood
```

```
# 명목척도->서열척도 # MILD 경증, MODERATE 중등증, SEVERE 중증
```

```
symptoms <- factor(c("SEVERE","MILD","MODERATE"),  
                  levels = c("MILD","MODERATE","SEVERE"),  
                  ordered = TRUE)
```

```
symptoms
```

```
symptoms > "MODERATE"
```

```
symptoms >= "MODERATE"
```

R 데이터 구조

– 리스트

```
#list
subject_name <- c("John Doe","Jane Doe","Steve Graves")
temperature <- c(98.1, 98.6, 101.4)
flu_status <- c(FALSE, FALSE, TRUE)
gender <- factor(c("MALE","FEMALE","MALE"))
blood <- factor(c("O","AB","A"),
               levels = c("A","B","AB","O"))
symptoms <- factor(c("SEVERE","MILD","MODERATE"),
                  levels = c("MILD","MODERATE","SEVERE"),
                  ordered = TRUE)
```

#첫 번째 환자의 전체 데이터

```
subject_name[1]
temperature[1]
flu_status[1]
gender[1]
blood[1]
symptoms[1]
```

R 데이터 구조

– 리스트

#모든 값을 하나의 객체로 그룹화해 반복적으로 사용

```
subject1 <- list(fullname=subject_name[1],  
                 temperature=temperature[1],  
                 flu_status=flu_status[1],  
                 gender=gender[1],  
                 blood=blood[1],  
                 symptoms=symptoms[1])
```

subject1

#list내 구성요소 추출

```
subject1[2]
```

#구성요소의 값(벡터)을 추출

```
subject1[[2]]
```

subject1\$temperature # \$리스트 구성요소 이름

#여러 구성요소 추출

```
subject1[c("temperature", "flu_status")]
```

R 데이터 구조

– 데이터 프레임

```
#dataframe
pt_data <- data.frame(subject_name, temperature, flu_status,
                      gender, blood, symptoms,
                      stringsAsFactors = FALSE)

pt_data
pt_data$subject_name
pt_data[c("temperature", "flu_status")]
pt_data[1,2] #환자 데이터 프레임의 첫번째 행, 두번째 열의 값 추출
pt_data[c(1,3), c(2,4)] #1,3번째 행과 2,4번째 열
pt_data[,1] #1번째 열의 모든 행 추출
pt_data[1,] #1번째 행의 모든 열 추출
pt_data[,] #모든 데이터 추출
pt_data[c(1,3),c("temperature", "gender")] # 숫자 혹은 열이름으로 추출
pt_data[-2, c(-1,-3,-5,-6)] #(-)부호로 행 또는 열 제외
pt_data$temp_c <- (pt_data$temperature-32)*(5/9)
pt_data
pt_data[c("temperature", "temp_c")]
```

R 데이터 구조

– 행렬

#행렬과 배열

```
m <- matrix(c(1,2,3,4), nrow = 2) # 열 우선 방식
```

```
m
```

```
m <- matrix(c(1,2,3,4), ncol = 2)
```

```
m
```

```
m <- matrix(c(1,2,3,4,5,6), nrow = 2)
```

```
m
```

```
m <- matrix(c(1,2,3,4,5,6), ncol = 2)
```

```
m
```

```
m[1,]
```

```
m[,1]
```

문제[1]

	x	y	q
1	10	-4	Hotkey
2	9	-3	Football
3	8	-2	Baseball
4	7	-1	Curling
5	6	0	Rugby
6	5	1	Lacrosse
7	4	2	Basketball
8	3	3	Tennis
9	2	4	Cricket
10	1	5	Soccer

- 함수 `data.frame`을 이용하여 위의 데이터 프레임(theDF)을 만들어라.
- 세 개의 벡터 `x`, `y`, `q`를 이용하여라.
- 열 이름을 다음과 같이 변경하여라.
 - First=`x`, Second=`y`, Sport=`q`
- theDF의 3,5행과 2,3열의 데이터를 출력하여라.